

KTB AI 성능 개선 대회

약관 QA 결과기 개선 여정

카카오테크 부트캠프 판교 4기 AI 실무개발 9조
eric.kim(김동주), linda.hwang(황수빈)

개선 목표와 접근 방향

공개 문항 적중과 비공개 문항 일반화를 동시에 확보

목표

10개 문항 골드셋에 최대한 적중해 높은 점수를 받는다.
30개 비공개 문항에도 잘 대답해, 공개 10문항에만 과적합되지 않도록 한다.

[데이터 구성]

검색은 BM25(어휘)와
BGE-M3 임베딩 (의미)를
융합한 하이브리드 방식.

[벡터 DB]

별도 벡터DB 없이
메모리(72x1024) 배열
하나로 처리.

청크가 72개뿐이라
전수 비교가 색인보다
더 빠르고 정확하다.

[모델 선택]

Qwen 7B 선택
Eric의 개인 프로젝트에
서 3B를 경험했고,
답변 생성 품질을 높이기
위해 7B로 확장했다.

[실행 제약]

Drive 마운트가 되지 않는
환경에서 문서를 어떻게
넣을지 해결해야 했다.

실험 설계와 방향

모델 메모리, 문서 투입, 검색·컨텍스트 구성을 분리해 판단

[양자화 NF4]

Qwen 7B fp16은 15.2GB라,
T4 16GB에 들어가지 않아
양자화가 필수였다.

NF4는 사전학습 가중치가
정규분포에 가깝다는 성질을 이용해
그 분포에 맞춰 4bit 값을 배치하는 자료형이다.

이중 양자화로 한 번 더 줄이고,
T4는 bf16을 지원하지 않아
dtype은 fp16으로 뒀다.

[MD 선택]

DOCX·HTML을 우선 쓰고
PDF는 최후 수단으로 뒀다.

PDF는 인쇄용이라 제목·문단 구조가 파일에 없고
머리말이 조문 사이에 끼어든다.

MD로 변환하면 ## 제N조 헤딩이 남아
정규식으로 조 단위 파싱이 가능했다.

변환 후 원본과 문자 단위로 대조했고(0.982~0.999),
그 대조에서 계정 약관이 구판인 것을 발견했다.

실험 설계와 방향

모델 메모리, 문서 투입, 검색·컨텍스트 구성을 분리해 판단

[유사도 검색]

두 검색기의 점수를 더하지 않고
순위를 더했다(RRF).

가중치는 고정하지 않고
질문마다 바꿨다.

: 1위가 뒤 순위를 크게 앞서면
그 검색기가 확신한 것으로 보고
 $w = 1.0 + 0.6 \times \text{확신도}$ 로
무게를 실었다.

[컨텍스트 조합]

top-4 조항을 본문째 넣되 예산을 뒀다.

조 하나 3,600자,
합계 7,200자 상한이다.

: 실측 최장 조가 3,564자,
top-4 합계 최대 7,080자라
어떤 조도 잘리지 않으면서
OOM을 막는 선이었다.

[프롬프트 설계]

규칙 14개를 7개로 압축했다
(1,488자 → 625자).

모델이 주의를 두는
맨 앞과 맨 뒤에
핵심을 배치했다.

개선과정과 기술선택 - 유사도 검색 : 동적 가중치 추가

검색층과 생성층을 각각 실험하고, 실패 원인을 다음 선택에 반영

유사도 검색층을 3계층으로 구성했다.

- ① BM25로 어휘 겹침 확인
- ② Dense로 의미 확인
- ③ 확신도 기반 동적 가중치
 - RRF 융합
 - top-4 선택

1) BM25 순위 : 어휘 겹침
2) Dense 순위 : 코사인, CHUNK_VECTORS @ q_vec
3) 확신도 기반 동적 가중치 → RRF 융합 → top-4 뽑기

Q: 대 점수를 안 더하고 순위들 더하냐?
A: BM25 점수와 코사인 유사도는 스케일이 달라 정규화 방식에 따라 결과가 다르다.
RRF (순위합산)이 이 문제를 해결하는법.

확신도 = (1위 점수 - 2세위 순위값) / 1위 점수

$W = 1.0 + 0.6 \times \text{확신도}$

$\text{fused}[i] += W / (60 + \text{rank} + 1)$

$\text{sorted}(\text{fused}, \dots)[:4]$


Q: 확신도는 왜 동적인가?
A: 질문마다 어느 검색기가 맞는지 다르다.
실제로 BM25 확신도 ≥ 0.5 인 문항은 MRR 0.938,
 < 0.5 는 0.688.
⇒ 확신도가 실제 성능과 연관이 있다는걸 확인하고 넣는다.

개선과정과 기술선택 - 유사도 검색 : 동적 가중치 추가

검색층과 생성층을 각각 실험하고, 실패 원인을 다음 선택에 반영

유사도 검색층을 3계층으로 구성했다.

- ① BM25로 어휘 겹침 확인
- ② Dense로 의미 확인
- ③ 확신도 기반 동적 가중치
 - RRF 융합
 - top-4 선택



개선과정과 기술선택 - 프롬프트

검색층과 생성층을 각각 실험하고, 실패 원인을 다음 선택에 반영

프롬프트

- ① 2중 프롬프트를 시도했지만 작업 수행은 이전과 같고 시간만 오래 걸렸다.
- ② qwen 7b는 프롬프트가 길어지면 T4에서 OOM(메모리부족)이 터졌다.
- ③ 그래서 프롬프트 1개를 유지하면서 더 압축했다.

```
SYSTEM_PROMPT = (  
    "당신은 제시된 카카오 약관 조항에서 답을 찾아 옮기는 도우미입니다.\n"  
    "답변은 새로 쓰는 글이 아니라, 조항에서 필요한 문장을 골라 옮기는 작업입니다.\n"  
    "\n"  
    "1. 한국어로만 씁니다. 다른 언어의 글자를 쓰지 않고, 번역하거나 다시 쓰겠다는 말을 "  
    "붙이지 않으며, 답변 본문만 한 번 출력합니다.\n"  
    "2. 고른 문장은 다듬지 말고 그대로 옮깁니다. 단어를 짧은 말로 바꾸거나, 나열된 말 중 "  
    "일부를 빼거나, 명사형으로 줄이지 않습니다. 수량·기간·비율·날짜·법령 이름·조문 번호와, "  
    "사람·기관·회사·서비스의 이름은 붙어 있는 호칭과 수식어까지 통째로 옮깁니다.\n"  
    "3. 답에 해당하는 문장 하나로 끝내지 마십시오. 같은 조 안에서 그 답의 조건·성격·범위를 "  
    "밝히거나 뒤따르는 조치를 정한 문장까지 함께 옮깁니다. 최대 세 문장입니다.\n"  
    "4. 질문이 두 가지 이상을 물으면 물은 순서대로 각각 답합니다. 누가·무엇을·어떤 방법으로·"  
    "어디에·언제까지·어떤 효력을 중 질문에 들어 있는 것을 빠뜨리지 않습니다. 열거를 물으면 "  
    "항목 이름과 그 옆에 적힌 설명을 함께, 질문이 밝힌 개수만큼 옮깁니다.\n"  
    "5. 조항이 여러 개 제시되면 질문에 가장 직접 답하는 조항을 골라 그 안의 문장만 씁니다. "  
    "조항에 없는 내용은 지어내지 말고 없다고 밝힙니다.\n"  
    "6. 질문의 전제를 믿지 말고 조항으로 확인합니다. 전제와 다르면 '아니오'로 시작해 "  
    "바로잡되, '예'와 '아니오'는 가부를 묻는 질문에만 씁니다. 근거가 된 조의 번호를 짧은 "  
    "어구로 한 번만 넣고, 서두나 맺음말 없이 같은 내용을 두 번 쓰지 않습니다.\n"  
    "\n"  
    "다시 확인하십시오. 한국어로만 쓸 것, 문장과 이름을 그대로 옮길 것, 답을 완성하는 "  
    "문장까지 함께 옮길 것, 질문이 물은 것을 빠뜨리지 말 것."  
)
```

개선과정과 기술선택 - FewShot

검색층과 생성층을 각각 실험하고, 실패 원인을 다음 선택에 반영

✓ Few-shot을 넣은 이유

유도 질문에 답이 이상했다. 예: '본 약관은 세부 지침보다 우선시하나요?'에 바로 '네'라고 답해 근거가 불충실했다.

✓ 첫 번째 수정의 문제

'<조항1>[예시 약관 제0조 (준칙)] 본 약관에 대해...'를 넣자 답변은 생성됐지만 문항을 못 찾고 retrieved에 제0조가 나왔다.

✓ 최종 few-shot 방향

실제 조문, 번호를 넣지 않고 답변 형식만 가르쳤다.


```
FEWSHOT = [
{
  "role": "user",
  "content": (
    "다음은 관련 약관 조항입니다.\n\n"
    "<조항 1>\n[예시 약관 (자료의 보관)]\n"
    "회사는 접수된 자료를 접수일부터 5년간 보관합니다. 보관기간이 지난 자료는 "
    "지체 없이 파기하며, 파기 사실을 이용자에게 따로 통지하지 않습니다.\n\n"
    "질문: 회사는 접수된 자료를 기간 제한 없이 계속 보관하나요?\n\n답변:"
  ),
},
{
  "role": "assistant",
  "content": (
    "아니오. 회사는 접수된 자료를 접수일부터 5년간 보관합니다. 보관기간이 지난 "
    "자료는 지체 없이 파기하며, 파기 사실을 이용자에게 따로 통지하지 않습니다."
  ),
},
{
  "role": "user",
  "content": (
    "다음은 관련 약관 조항입니다.\n\n"
    "<조항 1>\n[예시 약관 (설비의 점검)]\n"
    "본 서비스의 설비 점검은 회사가 위탁한 가나다기술 주식회사가 수행합니다. "
    "점검으로 서비스가 중단되는 경우 회사는 중단 사유와 중단 시간을 "
    "사전에 안내합니다.\n\n"
    "질문: 본 서비스의 설비 점검은 누가 수행하며, 점검으로 서비스가 중단되면 "
    "회사는 무엇을 안내하나요?\n\n답변:"
  ),
},
{
  "role": "assistant",
  "content": (
    "본 서비스의 설비 점검은 회사가 위탁한 가나다기술 주식회사가 수행합니다. "
    "점검으로 서비스가 중단되는 경우 회사는 중단 사유와 중단 시간을 "
    "사전에 안내합니다."
  ),
},
]
```


개선과정과 기술선택 - FewShot

검색층과 생성층을 각각 실험하고, 실패 원인을 다음 선택에 반영

- ❑ 동작 원리 - 그리디 1개 + 샘플링 3개 추출.
: 제일 확률이 높은 답 : 그리디 1개
: 그리디 1개의 생성된 답변에 단어를 더 적절한 단어로
변경하기 위해 샘플링 문항 3개도 추출.

- ❑ Temperature 변경
0.4에서는 그리디로 뽑은 답과 유사한 후보가 계속 나왔다.
그래서 0.7로 올려 후보 다양성을 확보.



품질과 속도의 균형에 대한 판단

7B의 품질을 유지하면서 후보 생성 비용을 조건부로 줄였다

3B는 질문 1개당 10초 이내로 나와 속도는 더 좋았지만, 답변 생성은 7B가 더 우수해서 7B를 선택했다.

7B를 사용하되 속도를 더 빠르게 하기 위해 early_stopping을 도입했다.

그리디가 0.95 이상이고 어미가 정상일 때는 샘플링 3개를 생략한다.

그보다 낮으면 샘플링 후보를 생성하고 조건부로 교체한다.


자체 평가를 통해 과적합을 방지했다.

```
print(f"\n[{r['qid']}] {r['ans'][:900]}")
```

```
=====
OK P01 [basic] 검색 1/1 RR 1.00 | 키팍트 100% | 1.1s | 141자
OK P02 [exact] 검색 3/3 RR 1.00 | 키팍트 100% | 1.3s | 495자
OK P03 [basic] 검색 1/1 RR 1.00 | 키팍트 100% | 1.5s | 698자
OK P04 [basic] 검색 1/1 RR 1.00 | 키팍트 100% | 1.0s | 100자
OK P05 [exact] 검색 1/1 RR 1.00 | 키팍트 100% | 1.2s | 517자
OK P06 [trap ] 검색 1/1 RR 1.00 | 키팍트 100% | 1.1s | 200자
OK P07 [basic] 검색 1/1 RR 1.00 | 키팍트 100% | 1.1s | 310자
!! P08 [trap ] 검색 1/1 RR 1.00 | 키팍트 50% | 0.9s | 127자
    누락: 아니오
!! P09 [trap ] 검색 1/1 RR 1.00 | 키팍트 50% | 1.3s | 214자
    누락: 전 세계적이고 영구적인 라이선스
OK P10 [basic] 검색 1/1 RR 1.00 | 키팍트 100% | 1.1s | 282자
OK H01 [exact] 검색 1/1 RR 1.00 | 키팍트 100% | 1.0s | 91자
!! H02 [basic] 검색 1/1 RR 1.00 | 키팍트 50% | 1.2s | 259자
    누락: 김연지
OK H03 [exact] 검색 1/1 RR 1.00 | 키팍트 100% | 4.6s | 106자
!! H04 [basic] 검색 1/1 RR 1.00 | 키팍트 100% | 6.2s | 151자
    답변이 문장 중간에서 끊김 -> MAX_NEW_TOKENS 를 올린다
OK H05 [trap ] 검색 1/1 RR 1.00 | 키팍트 100% | 1.2s | 326자
OK H06 [exact] 검색 1/1 RR 1.00 | 키팍트 100% | 3.2s | 70자
!! H07 [exact] 검색 1/1 RR 1.00 | 키팍트 50% | 2.9s | 72자
    누락: 사유 발생을 안 날로부터 1월
```

[정리] 검색·생성·선택을 한 흐름으로 묶었다

고정 코퍼스 → Hybrid Retrieval → Qwen 생성



실패는 구조를 단순하게 만들었고, 다음 병목을 남겼다

최종 공개 연습 결과 :

89.054 → 91.035 → 90.624 → (자체 평가 예측) 93.035

9팀 · 공개 10문항 연습 채점

총점 89.056 / 100

- MRR 1.0000 → 20.000점 (배점 20)
- 키팍트 F1 0.6877 → 20.631점 (배점 30)
- LLM 판정 96.850 → 48.425점 (배점 50)

문항별 판정 점수

- P01 판정 100.0 검색순위 1
- P02 판정 94.0 검색순위 1
- P03 판정 100.0 검색순위 1
- P04 판정 100.0 검색순위 1
- P05 판정 100.0 검색순위 1
- P06 판정 100.0 검색순위 1
- P07 판정 94.0 검색순위 1
- P08 판정 86.5 검색순위 1
- P09 판정 94.0 검색순위 1
- P10 판정 100.0 검색순위 1

9팀 · 공개 10문항 연습 채점

총점 91.035 / 100

- MRR 1.0000 → 20.000점 (배점 20)
- 키팍트 F1 0.7537 → 22.610점 (배점 30)
- LLM 판정 96.850 → 48.425점 (배점 50)

문항별 판정 점수

- P01 판정 100.0 검색순위 1
- P02 판정 94.0 검색순위 1
- P03 판정 100.0 검색순위 1
- P04 판정 100.0 검색순위 1
- P05 판정 100.0 검색순위 1
- P06 판정 100.0 검색순위 1
- P07 판정 100.0 검색순위 1
- P08 판정 86.5 검색순위 1
- P09 판정 94.0 검색순위 1
- P10 판정 94.0 검색순위 1

9팀 · 공개 10문항 연습 채점

총점 90.624 / 100

- MRR 1.0000 → 20.000점 (배점 20)
- 키팍트 F1 0.7400 → 22.199점 (배점 30)
- LLM 판정 96.850 → 48.425점 (배점 50)

문항별 판정 점수

- P01 판정 100.0 검색순위 1
- P02 판정 94.0 검색순위 1
- P03 판정 100.0 검색순위 1
- P04 판정 100.0 검색순위 1
- P05 판정 100.0 검색순위 1
- P06 판정 100.0 검색순위 1
- P07 판정 100.0 검색순위 1
- P08 판정 86.5 검색순위 1
- P09 판정 94.0 검색순위 1
- P10 판정 94.0 검색순위 1

실패는 구조를 단순하게 만들었고, 다음 병목을 남겼다

[실패]

추출과 작문을 두 단계로 나누면
누락이 줄 것으로 봤다.
그런데 1단계가 고른 문장을
2단계가 다시 요약하면서
키펙트가 0.861에서 0.576으로 떨어졌다.
: 단일 생성으로 되돌렸다.

7B로 바꾼 뒤 조항을 길이 제한 없이 넣었더니
프롬프트가 12,000자까지 부풀어
3문항에서 메모리가 터졌다.
: 답변이 통째로 비어 0점이 되는 실패라
조 하나 3,600자, 합계 7,200자로 상한을 뒀다.

낮은 온도가 원문에 더 가까울 것으로 봤지만
0.4에서는 그리디와 거의 같은 답만 나와
교체가 일어나지 않았다.
: 온도는 0.7로 두고 그리디를
기준선으로 고정했다.

[현재 한계]

공개 10문항은 MRR이 1.0으로 만점이다
그러나 어휘를 바꾼 질문에서는
BM25 재현율이 0.500까지 떨어졌다.
공개셋 만점은 검색이 끝났다는
뜻이 아니다.

자체 평가 셀은 후보끼리 비교하는 데는
쓸 수 있지만 공식 채점의 LLM 50점은
계산할 수 없다.
: 로컬 점수로 공식 총점을 예측할 수는 없다.

[다음 개선]

답변에서 빠지는 문장이 아직 남아 있다.
: 질문 유형별로 어떤 원문 구간을
옮길지 정하면 재현율을 더 올릴 수 있다.

자체 검증셋은 18문항이라 표본이 작다.
: 공개 문항이 다루지 않은 조항까지 넓혀
과적합을 계속 감시해야 한다.

후보를 4개 뽑았지만
교체가 일어난 문항은 P07 하나였다.
나머지 9문항은
그리디가 그대로 채택됐다.
: 후보가 서로 충분히 달라지게
만드는 것이 다음 과제다.

평가 항목(축) 설계가 가장 중요했다

검색·계산 로직은 검증된 구조를 따랐고, 실제로 손을 댄 지점은 Gemini 판정의 4개 축이었다

MRR·키팩트 F1은 계산으로 끝나는 지표라 운영진 채점 구조를 그대로 따랐다. 배점을 임의로 정하지 않고 이미 검증된 배분을 썼다.

판정 50점은 사람이 읽어야 판단 가능한 부분이라 LLM에 맡겼고, 그 안의 4개 축(정확성·근거성·완결성·명료성)을 어떻게 정의하는지가 평가기의 신뢰도를 결정했다.

근거성은 '인용을 안 한 것'과 '틀리게 인용한 것'을 구분해, 틀린 인용을 더 무겁게 감점하도록 설계했다.

완결성·명료성은 표현이 달라도 사실이 같으면 감점하지 않도록 못박아, 키팩트 F1과 같은 것을 두 번 깎지 않게 했다.

총점 100점 구성

검색 순위	키팩트	판정
MRR	F1	Gemini
20점	30점	50점

판정 50점 내부 구성

●	정확성	40%	사실이 정답과 일치하는가
●	근거성	25%	정답 조항에 근거하는가
●	완결성	20%	키팩트를 빠짐없이 담았는가
●	명료성	15%	군더더기 없이 읽히는가

공개셋 만점에 멈추지 않고, 질문별 확신도를 실험했다

대회에서 남긴 것

1. 하이브리드 방식을 채택 했을 때 얻는 이점이 많다
2. LLM은 학습 데이터 양과 프롬프트가 중요하다
3. 때문에 작은 메모리를 사용하면 양자화를 활용해야 한다
4. 동적 가중치를 활용해 질문마다 가중치를 변경하면 좋은 답을 얻을 확률이 올라간다
5. OOM이 생각보다 잘 터져서 메모리 관리가 필수적이다